

Statystyka Matematyczna

Ćwiczenia

Zadanie 7.6

Mamy próbkę X_1, \dots, X_n z rozkładu danego gęstością:

$$f_{\theta}(x) = \frac{3x^2}{\theta^3} I(0, \theta)(x)$$

Badamy następującą parę hipotez:

$$\begin{cases} H : \theta = \frac{1}{3} \\ K : \theta = \frac{2}{3} \end{cases}$$

Można to zadanie rozwiązać na dwa sposoby.

Pierwszy sposób to skorzystanie z Lematu Neymana-Pearsona. Postać testu:

$$\phi(\mathbb{X}) = \begin{cases} 1 & \text{gdy } f_{\frac{2}{3}}(x_1, \dots, x_n) > k f_{\frac{1}{3}}(x_1, \dots, x_n) \\ 0 & \text{w.p.p.} \end{cases}$$

Zadanie 7.6

Przekształcamy gęstości:

$$\begin{aligned}
 f_{\frac{2}{3}}(x_1, \dots, x_n) &> k f_{\frac{1}{3}}(x_1, \dots, x_n) \\
 &= \frac{3^n \prod_{i=1}^n x_i^2}{\left(\frac{2}{3}\right)^{3n}} I\left(0, \frac{2}{3}\right)(x_{n:n}) > k \frac{3^n \prod_{i=1}^n x_i^2}{\left(\frac{1}{3}\right)^{3n}} I\left(0, \frac{1}{3}\right)(x_{n:n}) \\
 &\iff \frac{1}{8^n} I\left(0, \frac{2}{3}\right)(x_{n:n}) > k I\left(0, \frac{1}{3}\right)(x_{n:n}) \\
 &\iff I\left(0, \frac{2}{3}\right)(x_{n:n}) > k' I\left(0, \frac{1}{3}\right)(x_{n:n})
 \end{aligned}$$

Zatem dla $\frac{1}{3} < x_{n:n} < \frac{2}{3}$ zawsze odrzucamy, podczas gdy dla $0 < x_{n:n} < \frac{1}{3}$ zawsze odrzucamy jeśli $k' < 1$ lub zawsze przyjmujemy gdy $k' > 1$. Zatem nie możemy znaleźć k' takiego, że:

$$\begin{aligned}
 E_{\frac{1}{3}} \phi(\mathbb{X}) &= \mathbb{P}_{\frac{1}{3}}(\phi(\mathbb{X}) = 1) = \mathbb{P}_{\frac{1}{3}}\left(I\left(0, \frac{2}{3}\right)(x_{n:n}) > k' I\left(0, \frac{1}{3}\right)(x_{n:n})\right) \\
 &= \mathbb{P}_{\frac{1}{3}}\left(I\left(0, \frac{1}{3}\right)(x_{n:n}) > k' I\left(0, \frac{1}{3}\right)(x_{n:n})\right) = \alpha
 \end{aligned}$$

Zadanie 7.6

Jedyne wyjście w tym przypadku - randomizacja. Przyjmujemy, że $k' > 1$ np. $k' = 1.8$ i rozpatrujemy następujący test:

$$\phi(\mathbb{X}) = \begin{cases} \alpha & \text{gdy } 0 < X_{n:n} < \frac{1}{3} \\ 1 & \text{gdy } \frac{1}{3} < X_{n:n} < \frac{2}{3} \end{cases}$$

Wówczas:

$$\begin{aligned} E_{\frac{1}{3}} \phi(\mathbb{X}) &= \alpha \mathbb{P}_{\frac{1}{3}}(\phi(\mathbb{X}) = \alpha) = \alpha \mathbb{P}_{\frac{1}{3}}(0 < X_{n:n} < \frac{1}{3}) + 1 \mathbb{P}_{\frac{1}{3}}(\frac{1}{3} < X_{n:n} < \frac{2}{3}) \\ &= \alpha \end{aligned}$$

Policzmy moc tego testu:

$$M = E_{\frac{2}{3}} \phi(\mathbb{X}) = \alpha \mathbb{P}_{\frac{2}{3}}(0 < X_{n:n} < \frac{1}{3}) + 1 \mathbb{P}_{\frac{2}{3}}(\frac{1}{3} < X_{n:n} < \frac{2}{3})$$

Widzimy, że:

$$\mathbb{P}_{\frac{2}{3}}(0 < X_{n:n} < \frac{1}{3}) = F_X(\frac{1}{3})^n = \left(\frac{\frac{1}{3}}{\frac{2}{3}}\right)^{3n} = \frac{1}{8^n}$$

Zadanie 7.6

A także:

$$\mathbb{P}_{\frac{2}{3}}\left(\frac{1}{3} < X_{n:n} < \frac{2}{3}\right) = F_X\left(\frac{2}{3}\right)^n - F_X\left(\frac{1}{3}\right)^n = 1 - \frac{1}{8^n}$$

Zatem:

$$M = \alpha \frac{1}{8^n} + 1 - \frac{1}{8^n} = 1 - \frac{1 - \alpha}{8^n} = 1 - \frac{0.99}{8^n}$$

Drugi sposób. Nasza przestrzeń parametrów jest równa $\Theta = \{\frac{1}{3}, \frac{2}{3}\}$ zatem hipotezę:

$$\begin{cases} H : \theta = \frac{1}{3} \\ K : \theta = \frac{2}{3} \end{cases}$$

mogę przedstawić jako:

$$\begin{cases} H : \theta \leq \frac{1}{3} \\ K : \theta > \frac{1}{3} \end{cases}$$

Zadanie 7.6

I zastosować tw. Karłina-Rubina. Wpierw wykażemy, że nasza rodzina rozkładów ma monotoniczny iloraz wiarygodności, Rozpatrzmy $\theta_1 > \theta_0$:

$$\begin{aligned} \frac{p_{\theta_0}(x_1, \dots, x_n)}{p_{\theta_1}(x_1, \dots, x_n)} &= \frac{\frac{3^n \prod_{i=1}^n x_i^2}{(\theta_0)^{3n}} I(0, \theta_0)(x_{n:n})}{\frac{3^n \prod_{i=1}^n x_i^2}{(\theta_1)^{3n}} I(0, \theta_1)(x_{n:n})} \\ &= \frac{\theta_1^{3n}}{\theta_0^{3n}} \frac{I(0, \theta_0)(x_{n:n})}{I(0, \theta_1)(x_{n:n})} \end{aligned}$$

Widzimy, że jest to funkcja nierosnąca funkcją $x_{n:n}$. Zatem test ma postać:

$$\phi(\mathbb{X}) = \begin{cases} 1 & \text{gdy } X_{n:n} \geq c \\ 0 & \text{w.p.p.} \end{cases}$$

Zadanie 7.6

Znajdujemy c :

$$\mathbb{P}_{\frac{1}{3}}(X_{n:n} \geq c) = 1 - F_{X_{n:n}}(c) = 1 - (F_X(c))^n = \alpha$$

$$(1 - \alpha)^{\frac{1}{n}} = F_X(c) = (3c)^3$$

$$c = \frac{(1 - \alpha)^{\frac{1}{3n}}}{3}$$

P.d. policzyć moc.

Zadanie 7.7

Mamy próbkę X_1, \dots, X_{n_1} z rozkładu $Bern(\theta_1)$ i Y_1, \dots, Y_{n_2} z rozkładu $Bern(\theta_2)$. Mamy zweryfikować następującą parę hipotez:

$$\begin{cases} H : \theta_1 = \theta_2 \\ K : \theta_1 \neq \theta_2 \end{cases}$$

Rozpatrujemy następującą statystykę:

$$\bar{X} - \bar{Y}$$

Przy założeniu hipotezy zerowej wiemy, że:

$$E X_i = E Y_i = \theta_1$$

$$\text{Var } X_i = \text{Var } Y_i = \theta_1(1 - \theta_1)$$

Z CTG wiemy, że:

$$\sqrt{n_1}(\bar{X} - \theta_1) \xrightarrow{d} N\left(0, \sqrt{\theta_1(1 - \theta_1)}\right) \text{ i } \sqrt{n_2}(\bar{Y} - \theta_1) \xrightarrow{d} \sim N\left(0, \sqrt{\theta_1(1 - \theta_1)}\right)$$

Zadanie 7.7

Zatem dla dostatecznie dużej próby:

$$\bar{X} \sim N \left(\theta_1, \sqrt{\frac{\theta_1(1-\theta_1)}{n_1}} \right) \text{ i } \bar{Y} \sim N \left(\theta_1, \sqrt{\frac{\theta_1(1-\theta_1)}{n_2}} \right)$$

Zauważmy, że \bar{X} i \bar{Y} są niezależne, zatem:

$$\bar{X} - \bar{Y} \sim N \left(0, \sqrt{\theta_1(1-\theta_1) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right)$$

Wariancja może być zapisana jako:

$$\theta_1(1-\theta_1) \left(\frac{1}{n_1} + \frac{1}{n_2} \right) = \frac{\theta_1(1-\theta_1)}{\frac{n_1 n_2}{n_1 + n_2}}$$

Zatem:

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\theta_1(1-\theta_1)}{\frac{n_1 n_2}{n_1 + n_2}}}} \sim N(0, 1)$$

Zadanie 7.7

Zauważmy, że:

$$p^* = \frac{\sum_{i=1}^{n_1} X_i + \sum_{i=1}^{n_2} Y_i}{n_1 + n_2}$$

przy założeniu hipotezy zerowej zbiega do θ_1 . Zatem dla odpowiednio dużej próby

$$\sqrt{p^*(1-p^*)} \approx \sqrt{\theta_1(1-\theta_1)}$$

Więc ostatecznie statystyka testowa:

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{p^*(1-p^*)}{\frac{n_1 n_2}{n_1 + n_2}}}} \sim N(0, 1)$$

Zadanie 7.12

Mamy dwie próbki z rozkładu Poissona $X_1, \dots, X_{100} \sim \text{Pois}(\lambda_1)$ i $Y_1, \dots, Y_{100} \sim \text{Pois}(\lambda_2)$. Wiemy, że $\bar{X} = 20$ i $\bar{Y} = 22$.

Para hipotez:

$$\begin{cases} H : \lambda_1 = \lambda_0 \\ K : \lambda_1 \neq \lambda_0 \end{cases}$$

Mamy zbadać parę hipotez testem ilorazu wiarygodności. Nasza przestrzeń parametrów $\Theta = \{\lambda_1, \lambda_2\}$. Z kolei $\Theta_0 = \{\lambda = \lambda_1 = \lambda_2\}$. Policzmy:

$$\sup_{\lambda_1, \lambda_2 \in \Theta_0} L(\mathbb{X}, \lambda_1, \lambda_2) = \sup_{\lambda} L(\mathbb{X}, \lambda, \lambda)$$

Szukamy argumentu, który zmaksymalizuje nam wartość $L(\mathbb{X}, \lambda_1, \lambda_2)$ przy założeniu, że $\lambda = \lambda_1 = \lambda_2$. Zatem:

$$l(\mathbb{X}, \lambda, \lambda) = \ln \left(\prod_{i=1}^n \left(\frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \right) \prod_{i=1}^n \left(\frac{\lambda^{y_i} e^{-\lambda}}{y_i!} \right) \right)$$

Zadanie 7.12

$$\begin{aligned}
&= \ln \left(\frac{\lambda^{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i} e^{-2\lambda n}}{\prod_{i=1}^n (x_i! y_i!)} \right) \\
&= \left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right) \ln \lambda - 2\lambda n - \ln \left(\prod_{i=1}^n (x_i! y_i!) \right) \\
\frac{d}{d\lambda} l(\mathbb{X}, \lambda, \lambda) &= \left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right) \frac{1}{\lambda} - 2n = 0 \\
\hat{\lambda} &= \frac{\sum_{i=1}^n X_i + \sum_{i=1}^n Y_i}{2n}
\end{aligned}$$

Druga pochodna:

$$\frac{d^2}{d\lambda^2} l(\mathbb{X}, \lambda, \lambda) = - \left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right) \frac{1}{\lambda^2} < 0$$

Zadanie 7.12

Teraz poszukamy

$$\sup_{\lambda_1, \lambda_2 \in \Theta} L(\mathbb{X}, \lambda_1, \lambda_2) = \sup_{\lambda_1, \lambda_2} L(\mathbb{X}, \lambda_1, \lambda_2)$$

Zatem:

$$\begin{aligned} l(\mathbb{X}, \lambda_1, \lambda_2) &= \ln \left(\prod_{i=1}^n \left(\frac{\lambda_1^{x_i} e^{-\lambda_1}}{x_i!} \right) \prod_{i=1}^n \left(\frac{\lambda_2^{y_i} e^{-\lambda_2}}{y_i!} \right) \right) \\ &= \ln \left(\frac{\lambda_1^{\sum_{i=1}^n x_i} \lambda_2^{\sum_{i=1}^n y_i} e^{-(\lambda_1 + \lambda_2)n}}{\prod_{i=1}^n (x_i! y_i!)} \right) \\ &= \sum_{i=1}^n x_i \ln \lambda_1 + \sum_{i=1}^n y_i \ln \lambda_2 - (\lambda_1 + \lambda_2)n - \ln \left(\prod_{i=1}^n (x_i! y_i!) \right) \end{aligned}$$

Zadanie 7.12

$$\frac{d}{d\lambda_1} l(\mathbb{X}, \lambda_1, \lambda_2) = \sum_{i=1}^n x_i \frac{1}{\lambda_1} - n = 0$$

$$\hat{\lambda}_1 = \frac{\sum_{i=1}^n X_i}{n}$$

Druga pochodna:

$$\frac{d^2}{d\lambda_1^2} l(\mathbb{X}, \lambda_1, \lambda_2) = - \sum_{i=1}^n x_i \frac{1}{\lambda_1^2} < 0$$

Analogicznie dla λ_2 :

$$\frac{d}{d\lambda_2} l(\mathbb{X}, \lambda_1, \lambda_2) = \sum_{i=1}^n y_i \frac{1}{\lambda_2} - n = 0$$

$$\hat{\lambda}_2 = \frac{\sum_{i=1}^n Y_i}{n}$$

$$\frac{d^2}{d\lambda_2^2} l(\mathbb{X}, \lambda_1, \lambda_2) = - \sum_{i=1}^n y_i \frac{1}{\lambda_2^2} < 0$$

Zadanie 7.12

Więc:

$$\begin{aligned}
 \lambda(\mathbb{X}) &= \frac{\sup_{\lambda} L(\mathbb{X}, \lambda, \lambda)}{\sup_{\lambda} L(\mathbb{X}, \lambda_1, \lambda_2)} = \frac{\frac{\hat{\lambda}^{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i} e^{-2\hat{\lambda}n}}{\prod_{i=1}^n (x_i! y_i!)}}{\frac{\hat{\lambda}_1^{\sum_{i=1}^n x_i} \hat{\lambda}_2^{\sum_{i=1}^n y_i} e^{-(\hat{\lambda}_1 + \hat{\lambda}_2)n}}{\prod_{i=1}^n (x_i! y_i!)}} \\
 &= \frac{\hat{\lambda}^{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i} e^{-2\hat{\lambda}n}}{\hat{\lambda}_1^{\sum_{i=1}^n x_i} \hat{\lambda}_2^{\sum_{i=1}^n y_i} e^{-(\hat{\lambda}_1 + \hat{\lambda}_2)n}} \\
 &= \frac{\left(\frac{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i}{2n} \right)^{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i} e^{-(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i)}}{\left(\frac{\sum_{i=1}^n x_i}{n} \right)^{\sum_{i=1}^n x_i} \left(\frac{\sum_{i=1}^n y_i}{n} \right)^{\sum_{i=1}^n y_i} e^{-(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i)}} \\
 &= \frac{\left(\frac{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i}{2n} \right)^{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i}}{\left(\frac{\sum_{i=1}^n x_i}{n} \right)^{\sum_{i=1}^n x_i} \left(\frac{\sum_{i=1}^n y_i}{n} \right)^{\sum_{i=1}^n y_i}}
 \end{aligned}$$

Zadanie 7.12

Rozpatrujemy statystykę $-2 \ln \lambda(\mathbb{X})$.

$$\begin{aligned}
 -2 \ln \lambda(\mathbb{X}) &= -2 \left(\left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right) \ln \left(\frac{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i}{2n} \right) \right. \\
 &\quad \left. - \sum_{i=1}^n x_i \ln \left(\frac{\sum_{i=1}^n x_i}{n} \right) - \sum_{i=1}^n y_i \ln \left(\frac{\sum_{i=1}^n y_i}{n} \right) \right) \\
 &= -2(4200 \ln(21) - 2000 \ln(20) - 2200 \ln(22)) \approx 9.53
 \end{aligned}$$

Rozkład statystyki przy założeniu H_0 jest χ_1^2 . Przedział krytyczny:

$$(-\infty, \chi_{1,0.005}^2] \cup [\chi_{1,0.995}^2, \infty) = (-\infty, 0.00004] \cup [7.88, \infty)$$

Zatem nasza statystyka znajduje się w przedziale krytycznym, zatem przeciętne wartości są istotnie różne.

Zadanie 8.2

Chcemy sprawdzić, czy wygenerowana próba pochodzi z rozkładu $Bin(3, 0.5)$:

Wygenerowana liczba losowa	0	1	2	3
Liczba uzyskanych parametrów	12	37	38	13

Liczba parametrów szacowanych z próby jest równa 1 (pierwszy parametr jest ustalony). Liczymy statystykę testową:

$$\begin{aligned}
 T &= \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} = \frac{(12 - 100 * 0.125)^2}{100 * 0.125} + \frac{(37 - 100 * 0.375)^2}{100 * 0.375} \\
 &\quad + \frac{(38 - 100 * 0.375)^2}{100 * 0.375} + \frac{(13 - 100 * 0.125)^2}{100 * 0.125} \\
 &= 2 \frac{0.25}{12.5} + 2 \frac{0.25}{37.5} = 0.04 + 0.013 = 0.053
 \end{aligned}$$

Przedział krytyczny:

$$\kappa_\alpha = [\chi_{1-\alpha, k-1-r}^2, \infty) = [\chi_{0.95, 2}^2, \infty) = [5.991, \infty)$$

Jesteśmy poza przedziałem krytycznym zatem nie ma podstaw do odrzucenia

Zadanie 8.8

Chcemy zbadać zależność między spędzania wakacji. Tabela:

	góry	jeziora	morze
kobiety	32	32	41
mężczyźni	39	33	23

$$\Sigma r_1 = 105$$

$$\Sigma r_2 = 95$$

$$\text{200}$$

Statystyka testowa:

$$\frac{\Sigma \text{wiersz} \cdot \Sigma \text{kolumna}}{\Sigma \text{wszystko}}$$

$$T = \sum_{i=1}^{rc} \frac{(O_i - E_i)^2}{E_i} = \frac{(32 - \frac{105 \cdot 71}{200})^2}{\frac{105 \cdot 71}{200}} + \frac{(32 - \frac{105 \cdot 65}{200})^2}{\frac{105 \cdot 65}{200}} + \frac{(41 - \frac{105 \cdot 64}{200})^2}{\frac{105 \cdot 64}{200}} + \frac{(39 - \frac{95 \cdot 71}{200})^2}{\frac{95 \cdot 71}{200}} + \frac{(33 - \frac{95 \cdot 65}{200})^2}{\frac{95 \cdot 65}{200}} + \frac{(23 - \frac{95 \cdot 64}{200})^2}{\frac{95 \cdot 64}{200}}$$

i-ta komórka tabeli

Zes

Weryfikacja hipotez o niezależności cech X i Y

Hipoteza zerowa H : cechy X i Y są niezależne

Hipoteza alternatywna K : cechy X i Y są zależne

Statystyka testowa $T = \sum_{i=1}^{rc} \frac{(O_i - E_i)^2}{E_i}$

gdzie O_i - liczba obserwacji w i -tej komórce, $E_i = \frac{R_i \cdot C_i}{n}$,

R_i - suma obserwacji w wierszu, w którym jest położona i -ta komórka,

C_i - suma obserwacji w kolumnie, do której należy i -ta komórka,

r - liczba wierszy, c - liczba kolumn w tabeli kontyngencji,

n - liczba wszystkich obserwacji,

Obszar krytyczny $\chi^2_{1-\alpha, (r-1)(c-1); +\infty}$

Zadanie 8.8

$$\begin{aligned}
 T &= \sum_{i=1}^{rc} \frac{(O_i - E_i)^2}{E_i} = \frac{(32 - 37.275)^2}{37.275} + \frac{(32 - 34.125)^2}{34.125} + \frac{(41 - 33.6)^2}{33.6} \\
 &\quad + \frac{(39 - 33.725)^2}{33.725} + \frac{(33 - 30.875)^2}{30.875} + \frac{(23 - 30.4)^2}{30.4} \\
 &= 0.746 + 0.132 + 1.63 + 0.825 + 0.146 + 1.801 = 5.28
 \end{aligned}$$

Przedział krytyczny:

$$\kappa_{\alpha} = [\chi_{1-\alpha, (r-1)(c-1)}^2, \infty) = [\chi_{0.95, 2}^2, \infty) = [5.991, \infty)$$

Jesteśmy poza przedziałem krytycznym zatem nie ma podstaw do odrzucenia hipotezy.